

Statistique Bayésienne

Devoir Maison 1

Exercice 1

1) La loi a posteriori de τ^2 est :

$$\begin{aligned}
 \pi(\tau^2 | y^{(T)}, \sigma^{(T)}, \sigma_0, \beta_0, \beta_1) &\propto f(y^{(T)}, \sigma^{(T)}, \sigma_0, \beta_0, \beta_1 | \tau^2) \pi(\tau^2) \\
 &\propto \underbrace{f(y^{(T)} | \sigma^{(T)}, \sigma_0, \beta_0, \beta_1, \tau^2)}_{\propto \tau^2} \underbrace{f(\sigma^{(T)} | \sigma_0, \beta_0, \beta_1, \tau^2)}_{\propto \tau^2} \underbrace{f(\sigma_0, \beta_0, \beta_1 | \tau^2)}_{\propto \tau^2} \pi(\tau^2) \\
 &\propto f(\sigma^{(T)} | \sigma_0, \beta_0, \beta_1, \tau^2) \pi(\tau^2) \\
 &\propto \prod_{t=1}^T \underbrace{f(\sigma_t | \sigma^{(t-1)}, \sigma_0, \beta_0, \beta_1, \tau^2)}_{\sim \mathcal{N}(\beta_0 + \beta_1 \sigma_{t-1}, \tau^2)} \pi(\tau^2) \\
 &\propto \prod_{t=1}^T \frac{1}{|\tau|} e^{-\frac{1}{2} \frac{(\sigma_t - \beta_0 - \beta_1 \sigma_{t-1})^2}{\tau^2}} (\tau^2)^{-c_0-1} e^{-\frac{d_0}{\tau^2}} \\
 &\propto \frac{1}{|\tau|^T} (\tau^2)^{-c_0-1} e^{-\frac{(d_0 + \frac{1}{2} \sum_{t=1}^T (\sigma_t - \beta_0 - \beta_1 \sigma_{t-1})^2)}{\tau^2}}
 \end{aligned}$$

Comme $|\tau|^T = \sqrt{\tau^2}^T = (\tau^2)^{\frac{T}{2}}$, on a alors :

$$\tau^2 | y^{(T)}, \sigma^{(T)}, \sigma_0, \beta_0, \beta_1 \sim \text{IG} \left(c_0 + \frac{T}{2}, d_0 + \frac{1}{2} \sum_{t=1}^T (\sigma_t - \beta_0 - \beta_1 \sigma_{t-1})^2 \right)$$

2) La loi a posteriori de β_0 est :

$$\begin{aligned}
 \pi(\beta_0 | y^{(T)}, \sigma^{(T)}, \sigma_0, \tau^2, \beta_1) &\propto f(y^{(T)}, \sigma^{(T)}, \sigma_0, \beta_1, \tau^2 | \beta_0) \pi(\beta_0) \\
 &\propto \underbrace{f(y^{(T)} | \sigma^{(T)}, \sigma_0, \beta_0, \beta_1, \tau^2)}_{\propto \beta_0} \underbrace{f(\sigma^{(T)} | \sigma_0, \beta_0, \beta_1, \tau^2)}_{\propto \beta_0} \underbrace{f(\sigma_0, \beta_1, \tau^2 | \beta_0)}_{\propto \beta_0} \pi(\beta_0) \\
 &\propto \prod_{t=1}^T \underbrace{f(\sigma_t | \sigma^{(t-1)}, \sigma_0, \beta_0, \beta_1, \tau^2)}_{\sim \mathcal{N}(\beta_0 + \beta_1 \sigma_{t-1}, \tau^2)} \pi(\beta_0) \\
 &\propto \prod_{t=1}^T e^{-\frac{1}{2} \frac{(\sigma_t - \beta_0 - \beta_1 \sigma_{t-1})^2}{\tau^2}} e^{-\frac{1}{2} \frac{(\beta_0 - \alpha_0)^2}{\gamma_0}} \\
 &\propto e^{-\frac{1}{2} \left[\frac{1}{\tau^2} \sum_{t=1}^T (\beta_0^2 - 2\beta_0(\sigma_t - \beta_1 \sigma_{t-1})) + \frac{\beta_0^2}{\gamma_0} - \frac{2\beta_0 \alpha_0}{\gamma_0} \right]} \\
 &\propto e^{-\frac{1}{2} \left[\left(\frac{T}{\tau^2} + \frac{1}{\gamma_0} \right) \beta_0^2 - 2\beta_0 \left(\frac{1}{\tau^2} \sum_{t=1}^T (\sigma_t - \beta_1 \sigma_{t-1}) + \frac{\alpha_0}{\gamma_0} \right) \right]} \\
 &\propto e^{-\frac{1}{2} \left(\frac{T}{\tau^2} + \frac{1}{\gamma_0} \right) \left(\beta_0 - \frac{\frac{1}{\tau^2} \sum_{t=1}^T (\sigma_t - \beta_1 \sigma_{t-1}) + \frac{\alpha_0}{\gamma_0}}{\frac{T}{\tau^2} + \frac{1}{\gamma_0}} \right)^2} \\
 &\propto e^{-\frac{1}{2} \left(\frac{T}{\tau^2} + \frac{1}{\gamma_0} \right) \left(\beta_0 - \frac{1}{\gamma_0 T + \tau^2} (\gamma_0 \sum_{t=1}^T (\sigma_t - \beta_1 \sigma_{t-1}) + \alpha_0 \tau^2) \right)^2}
 \end{aligned}$$

Ainsi,

$$\beta_0 \mid y^{(T)}, \sigma^{(T)}, \sigma_0, \tau^2, \beta_1 \sim \mathcal{N}\left(\frac{\tau^2}{\gamma_0 T + \tau^2} \alpha_0 + \frac{\gamma_0}{\gamma_0 T + \tau^2} \sum_{t=1}^T (\sigma_t - \beta_1 \sigma_{t-1}), \frac{\gamma_0 \tau^2}{\gamma_0 T + \tau^2}\right)$$

3) La loi a posteriori de β_1 est :

$$\begin{aligned} \pi\left(\beta_1 \mid y^{(T)}, \sigma^{(T)}, \sigma_0, \tau^2, \beta_0\right) &\propto f(y^{(T)}, \sigma^{(T)}, \sigma_0, \beta_0, \tau^2 \mid \beta_1) \pi(\beta_1) \\ &\propto \underbrace{f(y^{(T)} \mid \sigma^{(T)}, \sigma_0, \beta_1, \beta_0, \tau^2)}_{\perp \beta_1} f(\sigma^{(T)} \mid \sigma_0, \beta_0, \beta_1, \tau^2) \underbrace{f(\sigma_0, \beta_0, \tau^2 \mid \beta_1)}_{\perp \beta_1} \pi(\beta_1) \\ &\propto \prod_{t=1}^T \underbrace{f(\sigma_t \mid \sigma^{(t-1)}, \sigma_0, \beta_0, \beta_1, \tau^2)}_{\sim \mathcal{N}(\beta_0 + \beta_1 \sigma_{t-1}, \tau^2)} \pi(\beta_1) \\ &\propto \prod_{t=1}^T e^{-\frac{1}{2} \frac{(\sigma_t - \beta_0 - \beta_1 \sigma_{t-1})^2}{\tau^2}} e^{-\frac{1}{2} \frac{(\beta_1 - \alpha_1)^2}{\gamma_1}} \mathbf{1}_{(-1,1)}(\beta_1) \\ &\propto e^{-\frac{1}{2} \left[\frac{1}{\tau^2} \sum_{t=1}^T (\beta_1^2 \sigma_{t-1}^2 - 2\beta_1 \sigma_{t-1} (\sigma_t - \beta_0)) + \frac{\beta_1^2}{\gamma_1} - \frac{2\beta_1 \alpha_1}{\gamma_1} \right]} \mathbf{1}_{(-1,1)}(\beta_1) \\ &\propto e^{-\frac{1}{2} \left[\left(\frac{1}{\tau^2} \sum_{t=1}^T \sigma_{t-1}^2 + \frac{1}{\gamma_1} \right) \beta_1^2 - 2\beta_1 \left(\frac{1}{\tau^2} \sum_{t=1}^T \sigma_{t-1} (\sigma_t - \beta_0) + \frac{\alpha_1}{\gamma_1} \right) \right]} \mathbf{1}_{(-1,1)}(\beta_1) \\ &\propto e^{-\frac{1}{2} \left(\frac{1}{\tau^2} \sum_{t=1}^T \sigma_{t-1}^2 + \frac{1}{\gamma_1} \right) \left(\beta_1 - \frac{\frac{1}{\tau^2} \sum_{t=1}^T \sigma_{t-1} (\sigma_t - \beta_0) + \frac{\alpha_1}{\gamma_1}}{\frac{1}{\tau^2} \sum_{t=1}^T \sigma_{t-1}^2 + \frac{1}{\gamma_1}} \right)^2} \mathbf{1}_{(-1,1)}(\beta_1) \\ &\propto e^{-\frac{1}{2} \left(\frac{1}{\tau^2} \sum_{t=1}^T \sigma_{t-1}^2 + \frac{1}{\gamma_1} \right) \left(\beta_1 - \frac{1}{\gamma_1 \sum_{t=1}^T \sigma_{t-1}^2 + \tau^2} (\gamma_1 \sum_{t=1}^T \sigma_{t-1} (\sigma_t - \beta_0) + \alpha_1 \tau^2) \right)^2} \mathbf{1}_{(-1,1)}(\beta_1) \end{aligned}$$

On obtient donc :

$$\beta_1 \mid y^{(T)}, \sigma^{(T)}, \sigma_0, \tau^2, \beta_0 \sim \mathcal{N}\left(\frac{\gamma_1 \sum_{t=1}^T \sigma_{t-1} (\sigma_t - \beta_0) + \alpha_1 \tau^2}{\gamma_1 \sum_{t=1}^T \sigma_{t-1}^2 + \tau^2}, \frac{\gamma_1 \tau^2}{\gamma_1 \sum_{t=1}^T \sigma_{t-1}^2 + \tau^2}\right) \mathbf{1}_{(-1,1)}(\beta_1)$$

Exercice 2

1) La fonction de vraisemblance du modèle est :

$$\begin{aligned}\mathcal{L}(y^{(T)} \mid \gamma, \delta, \lambda) &= \prod_{t=1}^T f(y_t \mid y^{(t-1)}, \gamma, \delta, \lambda) \\ &= \prod_{t=1}^{\lambda} \frac{\gamma^{y_t} e^{-\gamma}}{y_t!} \prod_{t=\lambda+1}^T \frac{\delta^{y_t} e^{-\delta}}{y_t!}\end{aligned}$$

avec $y^{(T)}$ la même notation que dans l'exercice 1.

Ainsi,

$$\mathcal{L}(y^{(T)} \mid \gamma, \delta, \lambda) = \left(\prod_{t=1}^T \frac{1}{y_t!} \right) \gamma^{(\sum_{t=1}^{\lambda} y_t)} \delta^{(\sum_{t=\lambda+1}^T y_t)} e^{-\lambda\gamma - (T-\lambda)\delta}$$

2) L'algorithme de Gibbs

Pour utiliser l'algorithme de Gibbs, il est nécessaire de calculer les lois conditionnelles suivantes $(\gamma \mid y^{(T)}, \delta, \lambda)$, $(\delta \mid y^{(T)}, \gamma, \lambda)$ et $(\lambda \mid y^{(T)}, \gamma, \delta)$.

D'après le théorème de Bayes, on a

$$\begin{aligned}\pi(\gamma \mid y^{(T)}, \delta, \lambda) &\propto f(y^{(T)} \mid \gamma, \delta, \lambda) \underbrace{f(\delta, \lambda \mid \gamma)}_{\mathbb{1}_{\gamma}} \pi(\gamma) \\ &\propto \mathcal{L}(y^{(T)} \mid \gamma, \delta, \lambda) \underbrace{\pi(\gamma)}_{\sim \Gamma(a_1, a_2)} \\ &\propto \gamma^{(\sum_{t=1}^{\lambda} y_t)} \delta^{(\sum_{t=\lambda+1}^T y_t)} e^{-\lambda\gamma - (T-\lambda)\delta} \gamma^{a_1-1} e^{-\frac{\gamma}{a_2}} \mathbb{1}_{\gamma \geq 0} \\ &\propto \gamma^{a_1 + (\sum_{t=1}^{\lambda} y_t) - 1} e^{-\gamma(\lambda + \frac{1}{a_2})} \mathbb{1}_{\gamma \geq 0}\end{aligned}$$

On reconnaît ici une loi Γ , on a donc

$$\gamma \mid y^{(T)}, \delta, \lambda \sim \Gamma\left(a_1 + \sum_{t=1}^{\lambda} y_t, \frac{a_2}{1 + \lambda a_2}\right)$$

De même, on obtient

$$\delta \mid y^{(T)}, \gamma, \lambda \sim \Gamma\left(d_1 + \sum_{t=\lambda+1}^T y_t, \frac{d_2}{1 + (T-\lambda) d_2}\right)$$

Quant à λ , on a

$$\begin{aligned}\pi(\lambda \mid y^{(T)}, \gamma, \delta) &\propto f(y^{(T)} \mid \gamma, \delta, \lambda) \underbrace{f(\gamma, \delta \mid \lambda)}_{\perp \lambda} \pi(\lambda) \\ &\propto \gamma^{(\sum_{t=1}^{\lambda} y_t)} \delta^{(\sum_{t=\lambda+1}^T y_t)} e^{-\lambda(\gamma-\delta)} \frac{1}{T-1} \mathbb{1}_{\lambda \in \llbracket 1; T-1 \rrbracket}\end{aligned}$$

Une fois ces trois distributions définies, on peut appliquer l'algorithme de Gibbs.

On commence par initialiser les paramètres $\theta^{(0)} = (\gamma^{(0)}, \delta^{(0)}, \lambda^{(0)})$. On peut les tirer des distributions a priori.

Ensuite, on tire :

- $\gamma^{(1)}$ depuis $\pi(\gamma \mid y^{(T)}, \delta^{(0)}, \lambda^{(0)}) \sim \Gamma\left(a_1 + \sum_{t=1}^{\lambda^{(0)}} y_t, \frac{a_2}{1 + \lambda^{(0)} a_2}\right)$
- $\delta^{(1)}$ depuis $\pi(\delta \mid y^{(T)}, \gamma^{(1)}, \lambda^{(0)}) \sim \Gamma\left(d_1 + \sum_{t=\lambda^{(0)}+1}^T y_t, \frac{d_2}{1 + (T - \lambda^{(0)}) d_2}\right)$
- Et $\lambda^{(1)}$ depuis $\pi(\lambda \mid y^{(T)}, \gamma^{(1)}, \delta^{(1)}) \propto \gamma^{(1)} (\sum_{t=1}^{\lambda} y_t) \delta^{(1)} (\sum_{t=\lambda+1}^T y_t) e^{-\lambda(\gamma^{(1)} - \delta^{(1)})} \mathbb{1}_{\lambda \in \llbracket 1; T-1 \rrbracket}$

Finalement, on réitère cette étape avec $(\gamma^{(1)}, \delta^{(1)}, \lambda^{(1)})$, et ainsi de suite.

3) Implémentation sur des données

Pour cette question, l'implémentation de l'algorithme de Gibbs a été réalisée avec Python sur $n_{iter} = 5000$ itérations.

Dans un premier temps, on a pris les paramètres suivants pour les a priori :

- $a_1 = 1$
- $a_2 = 0.5$
- $d_1 = 0.5$
- $d_2 = 0.5$

On obtient les résultats suivants




FIGURE 1 – Évolution de λ au cours des 5000 itérations, pour $a_1 = 1, a_2 = 0.5, d_1 = 0.5$ et $d_2 = 0.5$

On voit λ oscille autour de sa moyenne 39.25 avec un écart-type de 2.48.

Ensuite, on peut regarder en détails la distribution des λ :

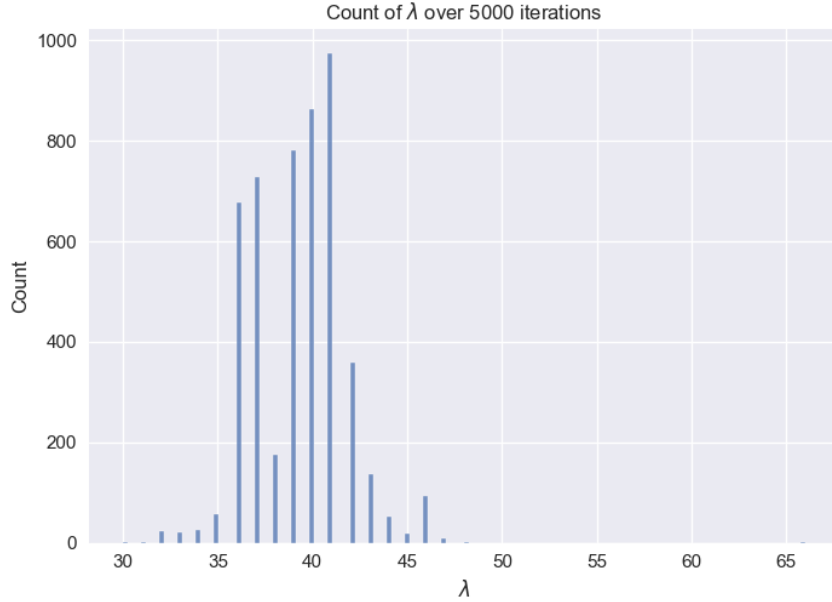


FIGURE 2 – Distribution des λ au cours des 5000 itérations, pour $a_1 = 1, a_2 = 0.5, d_1 = 0.5$ et $d_2 = 0.5$

De même, on peut regarder les distributions pour γ et δ .

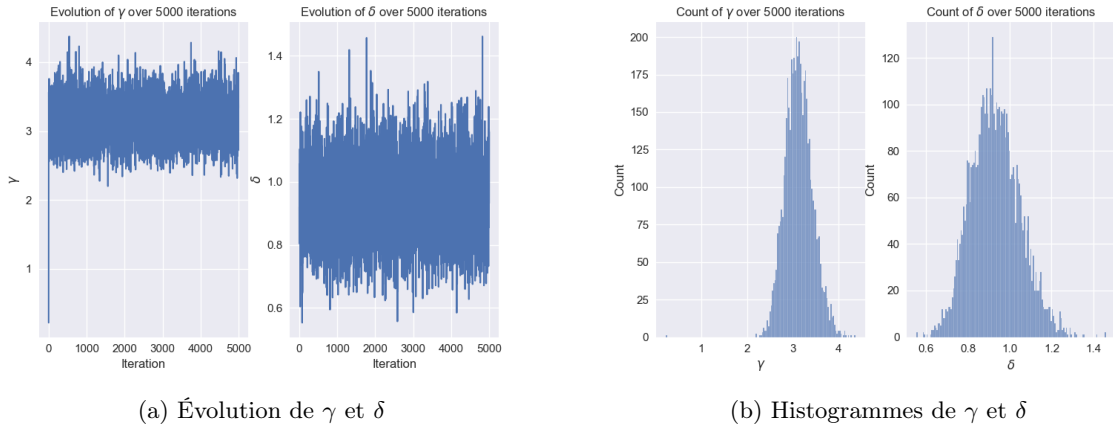


FIGURE 3 – Graphes pour γ et δ pour 5000 itérations, $a_1 = 1, a_2 = 0.5, d_1 = 0.5$ et $d_2 = 0.5$

γ a une moyenne de 3.13 et un écart-type de 0.30. Alors que δ a une moyenne de 0.93 et un écart-type de 0.12.

Ainsi, on a donc défini le point de changement en $\lambda = 39$ si on utilise la moyenne (il vaut 40 si on prend la médiane) et on observe effectivement un changement de comportement dans les données.

De plus, on constate que le choix des a priori ne changent pas le résultat.

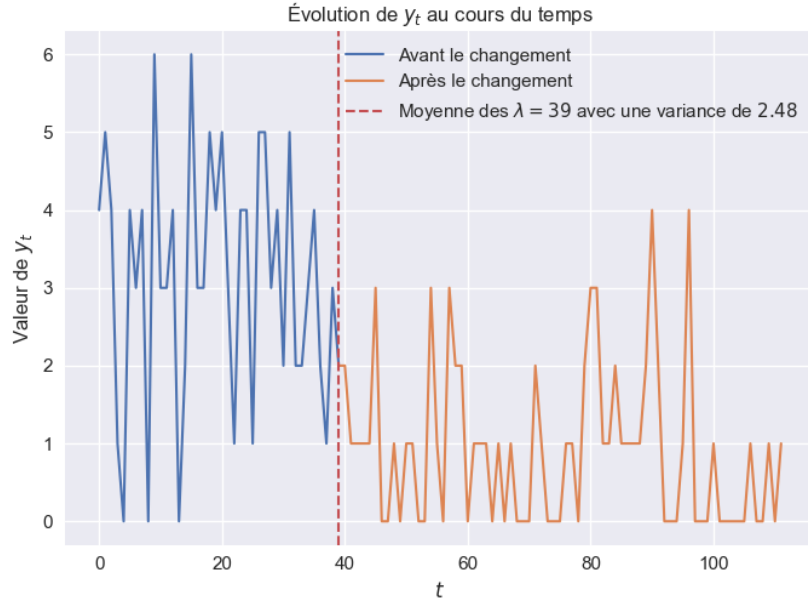


FIGURE 4 – Évolution du nombre d'accidents dans le temps séparé par le point de changement.

- Pour $a_1 = 1, a_2 = 1, d_1 = 2, d_2 = 0.5$, on a $\text{moy}(\lambda) = 39.44, \sigma(\lambda) = 2.52$ et $\text{median}(\lambda) = 40$.
- Pour $a_1 = 0.1, a_2 = 0.1, d_1 = 1, d_2 = 3$, on a $\text{moy}(\lambda) = 39.11, \sigma(\lambda) = 2.46$ et $\text{median}(\lambda) = 39$.
- Pour $a_1 = 1, a_2 = 1, d_1 = 1, d_2 = 1$, on a $\text{moy}(\lambda) = 39.33, \sigma(\lambda) = 2.49$ et $\text{median}(\lambda) = 40$.

On obtient également des résultats similaires quand on change le *seed*.

Finalement, quand on remarque que

- La moyenne des accidents avant le changement est de 3.15, avec un écart-type de 1.59.
- Puis, qu'il passe à 0.93 après le changement, avec un écart-type de 1.02.

Il y a donc bien un changement de comportement majeur après $t = 39$.

Le code est disponible sur GitHub à l'adresse suivante : <https://github.com/gwatkinson/DMStatsBayesiennes>